图神经网络

- 任务一、节点分类
  - 概要
    - GCN：通过图卷积层进行特征聚合，适用于图节点分类任务。
    - GAT：通过自注意力机制赋予邻居节点不同权重，适合处理异质图。
    - GraphSAGE：通过多种聚合函数（如均值、LSTM）进行特征聚合，提供了灵活的聚合方式。
    - GIN：利用强表达能力的聚合机制来学习节点特征，具有更高的表达能力。
  - 实验结果
    - Cora Dataset

      - GCN: 78.80%
      - GAT: 80.00%
      - GraphSAGE: 78.00%
      - GIN: 73.80%
    - Citeseer Dataset

      - GCN: 69.40%
      - GAT: 72.00%
      - GraphSAGE: 70.20%
      - GIN: 64.80%
    - 实验结果显示GAT表现最好，GCN和GraphSAGE接近，GIN效果最差且波动较为明显
- 任务二、链路预测

- 实验结果
  - Cora Dataset

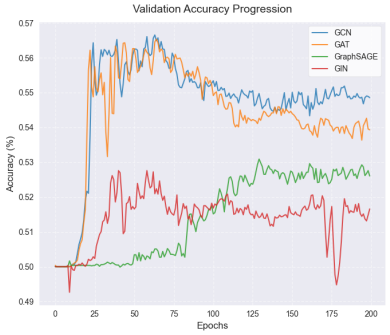

    - === 模型最佳验证精度 ===
    - GCN: 56.66%
    - GAT: 56.54%
    - GraphSAGE: 53.09%
    - GIN: 52.76%
    - 在Cora数据集上的结果显示GCN和GAT表现较好，GIN的表现最差且更加不稳定
    - 这反映出GCN作为基础模型在链路预测任务上有着较好的表现
  - Citeseer Dataset

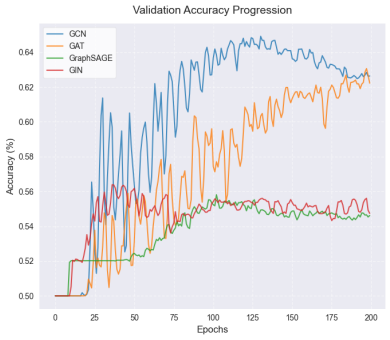

    - === 模型最佳验证精度 ===
    - GCN: 64.91%
    - GAT: 63.06%
    - GraphSAGE: 55.81%
    - GIN: 56.39%
    - 在Citeseer数据集上的结果显示GCN和GAT表现较好，GIN和GraphSAGE的表现较差
    - 对比loss图和Acc图，可以看到GIN和GraphSAGE的loss较低但同时Acc表现也较差，这反映出二者可能出现了过拟合的问题
- 实验三、图分类
  - 实验结果

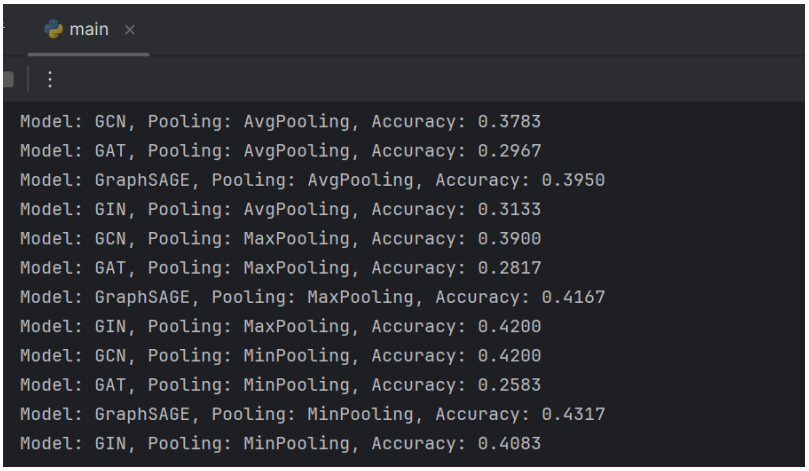

    - Model: GCN, Pooling: AvgPooling, Accuracy: 0.3783
    - Model: GAT, Pooling: AvgPooling, Accuracy: 0.2967
    - Model: GraphSAGE, Pooling: AvgPooling, Accuracy: 0.3950
    - Model: GIN, Pooling: AvgPooling, Accuracy: 0.3133
    - Model: GCN, Pooling: MaxPooling, Accuracy: 0.3900
    - Model: GAT, Pooling: MaxPooling, Accuracy: 0.2817
    - Model: GraphSAGE, Pooling: MaxPooling, Accuracy: 0.4167
    - Model: GIN, Pooling: MaxPooling, Accuracy: 0.4200
    - Model: GCN, Pooling: MinPooling, Accuracy: 0.4200
    - Model: GAT, Pooling: MinPooling, Accuracy: 0.2583
    - Model: GraphSAGE, Pooling: MinPooling, Accuracy: 0.4317
    - Model: GIN, Pooling: MinPooling, Accuracy: 0.4083
    - 其中GCN和GraphSAGE在三种池化方法中都表现出了较好的效果，反映出二者在图分类问题中的有效性
    - 对比三种池化方法，不同模型配合不同池化方法的结果各有优劣，综合来看MinPooling的表现较好
- 任务四、知识图谱
    - 概要
        - TransE：简单高效，适用于一对一的关系模式。
        - RotatE：能够有效捕捉复杂的关系模式，适用于多对多等复杂关系。
    - 实验结果

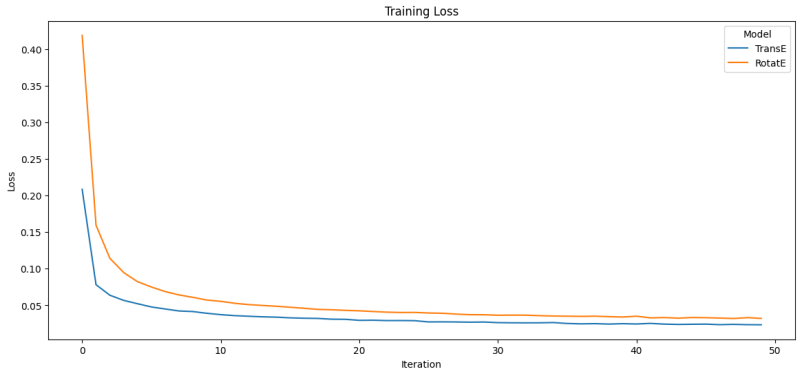

- 实验结果可以看出TransE的loss更低，反映出TransE模型在训练中的表现更好